

Université Paris Dauphine - PSL
Master 2 Ingénierie Statistique et Financière

**Projet Visualisation des
données avec R**

Comment expliquer le prix de l'électricité ?

Réalisé par
Sammy RABHINE

Encadrant
Quentin Guibert

Date de remise
3 janvier 2026

Table des matières

1	Introduction	2
1.1	Contexte	2
1.2	But du projet	2
2	Présentation des données	2
2.1	Sources et description	2
2.2	Nettoyages et retraitements des données	3
3	Analyse exploratoire des données	4
3.1	Distribution de la target FR vs DE	4
3.2	Principal Component Analysis	5
3.3	Regime Latent	6
3.4	Distribution des prix selon les régimes de marché	7
3.5	Matrices de formation des prix	8
3.6	Impact EnR sur les prix (quartiles)	9
4	Modélisation	9
4.1	Feature Engineering	9
4.2	Sélection des variables	10
4.3	Modèle XGBOOST	11
5	Résultats et interprétations	12
5.1	Résultats	12
5.2	Importance des variables	12
6	Conclusion et pistes d'améliorations	13
7	Utilisation de l'IA	14

1 Introduction

1.1 Contexte

Le prix de l'électricité est le résultat d'un équilibre complexe entre de nombreux facteurs économiques, climatiques, énergétiques et géopolitiques. À court terme, des variations locales des conditions météorologiques peuvent influencer simultanément la demande électrique (température, précipitations) et l'offre de production (vent, solaire, hydraulique). À plus long terme, des dynamiques structurelles telles que la transition énergétique ou le changement climatique modifient profondément les mix de production nationaux. Par ailleurs, le prix de l'électricité dépend fortement des coûts des matières premières utilisées pour la production (gaz, charbon, lignite, carbone), ainsi que des échanges transfrontaliers entre pays européens via des marchés intégrés et dynamiques. Ces mécanismes sont particulièrement marqués en Europe, où les réseaux électriques nationaux notamment ceux de la France et de l'Allemagne sont étroitement interconnectés. L'ensemble de ces interactions rend la modélisation du prix de l'électricité particulièrement délicate et nécessite une approche multifactorielle.

1.2 But du projet

L'objectif du challenge est d'expliquer les variations journalières du prix de contrats à terme (futurs) sur l'électricité à courte maturité (24 heures) pour deux pays européens : la France et l'Allemagne. Il ne s'agit pas d'un problème de prévision au sens strict, mais d'un problème d'explication statistique, visant à relier les fluctuations observées des prix à un ensemble de variables explicatives concomitantes. Plus précisément, les participants doivent construire un modèle capable d'estimer la variation quotidienne du prix des futures d'électricité à partir de données météorologiques, énergétiques (matières premières, production par filière) et commerciales (consommation, importations, exportations et échanges bilatéraux). La performance des modèles est évaluée à l'aide de la corrélation de Spearman entre les valeurs prédites et les variations réelles observées sur un jeu de données de test, privilégiant ainsi la capacité du modèle à capturer correctement la structure monotone des relations entre variables plutôt qu'une minimisation classique d'erreur quadratique.

2 Présentation des données

2.1 Sources et description

Les données sont fournies par QRT accessible sur ce lien. et couvrent deux zones géographiques : la France (FR) et l'Allemagne (DE).

Le jeu de données d'entraînement (`X_train`) comporte 1494 observations, et le jeu de test (`X_test`) en contient 654. Chaque ligne représente une journée pour un pays donné.

Les variables explicatives (35 colonnes) se regroupent en quatre catégories :

1. **Météorologie** : Température (`TEMP`), Pluie (`RAIN`), Vent (`WIND`).
2. **Production Énergétique** : Variations des coûts de production par filière (Gaz, Charbon, Nucléaire, Solaire, Éolien, etc.).
3. **Marché des Commodités** : Variations journalières des prix globaux (Gaz Europe `GAS_RET`, Charbon `COAL_RET`, Carbone `CARBON_RET`).
4. **Utilisation et Échanges** : Consommation totale, charge résiduelle (`RESIDUAL_LOAD`) et les imports/exports nets (`NET_IMPORT`, `DE_FR_EXCHANGE`).

La variable cible (`TARGET`) correspond à la variation journalière du prix du future électricité.

2.2 Nettoyages et retraitements des données

Une analyse systématique de la complétude des données a été réalisée afin d'identifier les variables présentant des valeurs manquantes. Celles-ci étant peu fréquentes et majoritairement liées à des indisponibilités ponctuelles de variables exogènes, un traitement spécifique a été appliqué en fonction de leur nature économique.

Les variables météorologiques et d'échanges transfrontaliers ont été imputées par interpolation linéaire, afin de préserver la continuité physique des phénomènes sous-jacents. Les flux nets, plus volatils, ont fait l'objet d'un traitement plus conservateur combinant interpolation sur de courtes périodes et lissage par moyenne mobile pour les lacunes résiduelles. Enfin, les valeurs manquantes en début ou en fin de série ont été corrigées par propagation de la dernière observation disponible, garantissant ainsi des séries complètes et cohérentes dans le temps.

Ces retraitements permettent de disposer d'un jeu de données entièrement exploitable, sans rupture artificielle, constituant un socle robuste pour l'analyse exploratoire et la modélisation.

3 Analyse exploratoire des données

3.1 Distribution de la target FR vs DE




FIGURE 1 – Distribution des variations de prix target entre la France et l’Allemagne

La distribution de la variable cible révèle d’emblée une caractéristique commune aux deux marchés : des variations de prix centrées autour de zéro mais avec des queues épaisses, signe que les événements extrêmes ne sont pas rares sur ces marchés. Ce constat est plus prononcé côté allemand, où l’on observe une dispersion nettement supérieure. Cette asymétrie entre les deux pays constitue un fait stylisé central de notre analyse, et les sections suivantes vont s’attacher à en comprendre les mécanismes sous-jacents plutôt qu’à simplement la constater à nouveau.

3.2 Principal Component Analysis




FIGURE 2 – Principal Component Analysis entre les variables économiques et physiques

Une analyse en composantes principales (PCA) a été réalisée afin de résumer la structure de dépendance entre les principales variables physiques et économiques du système électrique, tout en réduisant la dimension du problème. Les variables intégrées incluent la consommation, la production renouvelable (éolien et solaire), la production pilotable (nucléaire), les conditions météorologiques, ainsi que les prix des combustibles fossiles et du carbone, afin de capturer à la fois les contraintes physiques du réseau et les signaux de marché. Ce qui ressort clairement, c'est une opposition structurelle : d'un côté les énergies renouvelables, de l'autre la charge et les moyens pilotables. La deuxième composante, elle, capte essentiellement les signaux de prix des combustibles (gaz, charbon, carbone). Autrement dit, on retrouve bien les deux forces qui façonnent les prix de l'électricité la disponibilité physique et les coûts marginaux et l'ACP confirme qu'elles opèrent de manière relativement indépendante l'une de l'autre.

3.3 Régime Latent




FIGURE 3 – Régime latents du marché électrique européen

L'analyse par clustering révèle que le marché de l'électricité ne suit pas une trajectoire linéaire, mais alterne entre trois régimes latents aux dynamiques structurelles distinctes. Cette segmentation démontre l'inefficacité d'une modélisation uniforme et justifie l'intégration de variables non linéaires pour capturer ces changements d'état :

- **Régime EnR** : Caractérisé par une production éolienne et solaire massive qui sature l'offre. Dans cette configuration, les prix sont fortement comprimés, voire négatifs, car les énergies à coût marginal nul évincent les centrales thermiques conventionnelles.
- **Régime Intermédiaire** : Correspond à des conditions de marché standard où la demande est modérée et couverte par un mix énergétique diversifié. Les prix y sont stables, reflétant un équilibre sain entre la charge et les capacités de production disponibles.
- **Régime Stress** : Défini par une charge résiduelle élevée (forte consommation combinée à une faible production renouvelable). Le marché doit alors solliciter des unités de production coûteuses (gaz, charbon), entraînant une envolée des prix et une volatilité accrue selon la théorie du *Merit Order*.

3.4 Distribution des prix selon les régimes de marché

Distribution des prix selon les régimes de marché




FIGURE 4 – Distribution des prix selon les régimes de marché

En conditionnant les prix aux régimes identifiés précédemment, on voit que chaque état du marché a vraiment sa propre "signature" en termes de distribution. Le régime renouvelable produit des prix resserrés, parfois négatifs. Le régime de stress, lui, génère une dispersion bien plus large avec des pics importants. Ce n'est pas juste une question de moyenne différente, c'est la forme même de la distribution qui change, ce qui a des implications directes pour la gestion du risque et le choix des modèles.

3.5 Matrices de formation des prix




FIGURE 5 – Matrices de formation des prix selon la charge résiduelle et le prix du gaz

Ces matrices permettent de visualiser comment le prix réagit à la combinaison charge résiduelle / prix du gaz. La relation n'est clairement pas linéaire : les prix n'explorent vraiment que quand les deux variables sont simultanément élevées, ce qui est cohérent avec la logique du *Merit Order*. Ce qui est intéressant, c'est de voir à quel point cette interaction est plus "agressive" en Allemagne, les zones de prix élevés y sont plus étendues et plus marquées. En France, la surface est plus lisse, plus amortie. Cela donne une indication concrète sur la forme fonctionnelle qu'on pourrait vouloir capturer dans nos modèles.

3.6 Impact EnR sur les prix (quartiles)




FIGURE 6 – Impact de la production renouvelables sur les prix

Cette dernière analyse quantifie l’effet baissier des renouvelables sur les prix, qu’on s’attendait à observer d’après la théorie du *Merit Order*. L’effet médian est bien présent dans les deux pays. Mais ce qui est peut-être plus informatif pour la modélisation, c’est la dispersion autour de cette médiane : elle augmente fortement avec la production renouvelable, surtout en Allemagne. Autrement dit, plus il y a de renouvelables, plus l’incertitude sur le prix est grande, un effet qu’un modèle naïf pourrait facilement rater s’il ne capture que la tendance centrale.

4 Modélisation

4.1 Feature Engineering

Afin de capturer la nature fortement non linéaire et dynamique des prix de l’électricité, un ensemble de variables dérivées a été construit à partir des données brutes. Tout d’abord, des variables temporelles ont été introduites sous forme de retards de la variable cible (lags à 1, 2 et 24 pas de temps) ainsi que de statistiques glissantes (moyenne et volatilité sur 24 périodes), permettant au modèle d’intégrer à la fois l’inertie de court terme et les effets de persistance propres aux marchés électriques. Cette approche vise

à capturer les phénomènes de mémoire et de clustering de volatilité fréquemment observés dans les séries de prix de l'énergie.

Par ailleurs, le jeu de variables explicatives a été adapté séparément pour la France et l'Allemagne, afin de tenir compte des différences structurelles de leurs mix électriques. Les variables spécifiques à chaque pays ont été sélectionnées en priorité, tout en conservant certaines informations transfrontalières pertinentes pour refléter l'interconnexion des marchés européens. Enfin, des transformations non linéaires et des variables d'interaction ont été introduites afin de modéliser les mécanismes économiques sous-jacents à la formation des prix : effets quadratiques de la température, indicateurs de stress thermique combinant charge résiduelle et coûts des combustibles, ainsi que ratios de production renouvelable rapportés à la consommation. Ces variables visent à reproduire le fonctionnement du *Merit Order*, dans lequel le prix est fixé par la technologie marginale appelée, et à améliorer la capacité du modèle à discriminer les régimes de marché extrêmes.

4.2 Sélection des variables

La sélection des variables a été réalisée en deux étapes complémentaires, combinant une approche exploratoire guidée par l'analyse économique et une procédure quantitative visant à limiter la redondance informationnelle. Dans un premier temps, l'analyse exploratoire des données (distributions, PCA, graphiques d'impact des EnR, matrices charge-gaz) a permis d'identifier les variables physiquement et économiquement pertinentes pour chaque pays. Cette étape a motivé la construction de jeux de variables asymétriques entre la France et l'Allemagne : certaines variables allemandes (éolien, solaire, charge résiduelle, flux) ont été explicitement intégrées dans le modèle français afin de capturer les effets de couplage des marchés, tandis que des variables françaises moins informatives pour l'Allemagne ont été écartées.

Dans un second temps, une procédure automatique de nettoyage a été appliquée avant l'entraînement des modèles. Les variables à variance quasi nulle ont été supprimées, puis la multicolinéarité a été traitée en éliminant les variables fortement corrélées entre elles (corrélation de Spearman supérieure à 0.8). Cette étape vise à réduire la redondance entre indicateurs très proches (par exemple différentes mesures liées aux mêmes mécanismes physiques), à stabiliser l'apprentissage du modèle et à améliorer sa capacité de généralisation. La sélection finale conserve ainsi un ensemble de variables informatives, interprétables et non redondantes, cohérent à la fois avec l'analyse exploratoire préalable et avec les contraintes statistiques de la modélisation par arbres de décision.

4.3 Modèle XGBOOST

La modélisation des prix de l'électricité repose sur l'algorithme de *Gradient Boosting* XGBoost, qui approxime la fonction de prix comme une somme additive de modèles faibles (arbres de décision). Formellement, la prédiction s'écrit :

$$\hat{y}_i = \sum_{m=1}^M f_m(x_i), \quad f_m \in \mathcal{F},$$

où chaque f_m est un arbre de décision appartenant à l'espace des fonctions $\mathcal{F}$. À chaque itération, XGBoost ajoute un nouvel arbre en minimisant une fonction objectif composée d'un terme de perte et d'un terme de régularisation :

$$\mathcal{L} = \sum_{i=1}^n \ell(y_i, \hat{y}_i) + \sum_{m=1}^M \Omega(f_m), \quad \text{avec} \quad \Omega(f) = \gamma T + \frac{1}{2} \lambda \|w\|^2,$$

où T désigne le nombre de feuilles de l'arbre et w les poids associés. Dans notre approche, bien que la fonction de perte utilisée soit l'erreur quadratique moyenne, la variable cible est remplacée par son rang afin de privilégier la structure relative des prix :

$$\ell(y_i, \hat{y}_i) = (\text{rank}(y_i) - \hat{y}_i)^2.$$

Cette formulation conduit le modèle à préserver l'ordre relatif des observations plutôt que leurs niveaux absolus. L'évaluation des performances est alors réalisée à l'aide de la corrélation de Spearman, définie comme la corrélation de Pearson entre les rangs des valeurs observées et prédites :

$$\rho_S = \text{corr}(\text{rank}(y), \text{rank}(\hat{y})).$$

Cette stratégie permet d'aligner indirectement l'apprentissage du modèle avec l'objectif de classement des situations de marché, ce qui est particulièrement pertinent pour les prix de l'électricité, caractérisés par des distributions asymétriques, des queues épaisses et une forte dépendance aux régimes de fonctionnement du système électrique.

5 Résultats et interprétations

5.1 Résultats

Performance Détaillée (Cross-Validation 5 Folds)

Pays	Moyenne_Spearman	Ecart_Type	Fold_1	Fold_2	Fold_3	Fold_4	Fold_5
France	0.1592	0.0546	0.0847	0.1710	0.2218	0.1250	0.1934
Allemagne	0.3575	0.0926	0.3831	0.3211	0.3709	0.2295	0.4829

FIGURE 7 – Résultats des 2 modèles avec CV à 5 folds

Ces résultats montrent une différence nette de performance entre la France et l'Allemagne, mesurée via la corrélation de Spearman en validation croisée. Pour l'Allemagne, la corrélation moyenne élevée (0,36) indique que le modèle XGBoost parvient à ordonner correctement les variations de prix, ce qui suggère que les relations non linéaires entre prix, renouvelables, charge résiduelle et combustibles sont bien capturées. La dispersion entre folds reste modérée, malgré une variabilité plus forte liée à la nature intrinsèquement instable du marché allemand. À l'inverse, les performances plus faibles en France (0,16) traduisent un signal plus difficile à apprendre, cohérent avec le rôle amortisseur du nucléaire et une formation des prix moins sensible aux variations marginales des variables explicatives. Autrement dit, le modèle est plus performant là où le marché est structurellement plus volatil et piloté par des contraintes physiques variables (Allemagne), tandis que la stabilité du mix français limite la capacité prédictive en termes de classement relatif des prix.

5.2 Importance des variables




FIGURE 8 – features importances des variables XGBOOST

Les importances de variables issues de XGBoost confirment des mécanismes de formation des prix cohérents avec l’analyse économique préalable. En Allemagne, les variables physiques du système, en particulier l’éolien, la charge résiduelle et les flux nets, dominant, ce qui était attendu compte tenu de la forte dépendance aux renouvelables variables et de la sensibilité du marché aux contraintes d’équilibre. En France, les variables de marché et d’inertie temporelle (moyennes et volatilités roulantes, prix du carbone) apparaissent plus importantes, reflétant un système plus amorti par le nucléaire où la dynamique des prix est davantage lissée dans le temps. Ces résultats sont donc pleinement cohérents avec les différences structurelles observées lors de l’EDA et valident la pertinence du feature engineering réalisé.

6 Conclusion et pistes d’améliorations

Ce travail a permis de mettre en évidence les mécanismes structurels de formation des prix de l’électricité en France et en Allemagne à travers une approche combinant analyse exploratoire, identification de régimes latents et modélisation non linéaire. L’EDA a révélé des différences marquées entre les deux marchés : un système français plus amorti par le nucléaire et un marché allemand fortement exposé aux énergies renouvelables variables et aux contraintes physiques. L’identification de régimes latents via PCA, K-means et UMAP a confirmé l’existence de configurations de marché distinctes, associées à des profils de prix et de risque différenciés. Enfin, la modélisation par XGBoost, optimisée pour maximiser la corrélation de Spearman, montre une capacité prédictive significativement plus élevée en Allemagne qu’en France, en cohérence avec la plus grande volatilité et la non-linéarité du marché allemand. Les importances de variables confirment ces constats, en mettant en évidence le rôle central des contraintes physiques et des renouvelables en Allemagne, contre une dynamique plus inertielle et pilotée par les coûts en France.

Plusieurs axes peuvent être envisagés pour enrichir et renforcer cette approche. Premièrement, l’intégration plus explicite de la dynamique temporelle, via des horizons de lags multiples, des indicateurs de régime persistants ou des modèles séquentiels (LSTM, Temporal Convolutional Networks), permettrait de mieux capter les effets d’inertie et d’anticipation propres aux marchés électriques. Deuxièmement, les régimes latents identifiés pourraient être directement intégrés dans la modélisation, soit comme variables explicatives, soit via des modèles spécifiques par régime, afin de mieux capturer l’hétérogénéité structurelle des situations de marché. Enfin, une reformulation de l’objectif, par exemple en classification de quantiles de prix, en ranking pur ou en prédiction probabiliste, pourrait être plus adaptée à la nature leptokurtique et asymétrique de la target.

7 Utilisation de l'IA

L'IA générative a été utilisée tout au long de ce projet comme outil d'assistance méthodologique et analytique, notamment pour structurer l'analyse exploratoire, formuler des hypothèses économiques cohérentes et guider les choix de feature engineering. Elle a permis d'itérer rapidement sur la conception des variables, l'interprétation des régimes latents et la mise en cohérence des résultats de modélisation avec la théorie économique sous-jacente. L'IA générative a également contribué à la clarification et à la formalisation du raisonnement, en aidant à transformer des analyses quantitatives complexes en un storytelling lisible et rigoureux. Enfin, elle a servi de support à la rédaction scientifique, en assurant une présentation structurée, reproductible et alignée avec les standards académiques et industriels.